从自然语言到可验证推理：面向可靠 AI 数学的语义规约框架

作者姓名*

单位名称　author@example.edu

2026 年 9 月 27 日

摘要

大语言模型（LLM）在数学推理任务上的表现持续提升，但其输出以自然语言为载体，既不可直接验证，也无法稳定传导到形式化证明系统。本文提出一个统一的**三层分解模型**，把「可靠的 AI 数学推理」拆解为*生成层*（Generation Layer）、*语义规约层*（Semantic Reduction Layer）与*验证层*（Verification Layer）。基于对现有系统的分析，我们论证：当前系统的主要失败来源并非生成能力不足，也非验证器不可靠，而是*语义规约层*的缺失与不稳定——自然语言命题到形式对象之间的映射既不具备单值性（ambiguity），也不具备类型完整性（missing typing），更不具备可逆性（non-invertibility）。据此，本文提出以**类型化中间表示**（Typed Intermediate Representation, Typed IR）为核心的框架：将自然语言仅作为人机接口，把可验证结构作为执行内核，并通过**双向一致性**（Bidirectional Consistency）约束保证 IR 与自然语言之间的可解释性与可回溯性。我们给出框架的形式化定义、流水线架构（生成 $\to$ IR $\to$ 验证 $\to$ 渲染）以及可证伪的实验设计，并讨论其在自动定理证明、数学解题与 AI 教育三类场景中的应用。本文的贡献是概念性的：它把「语义规约」从工程细节提升为核心系统组件，并给出与之匹配的评估指标（可验证率、一致性、回译保真度）。

关键词：AI 数学；语义规约；类型化中间表示；自动形式化；神经符号系统；Curry–Howard 对应；形式验证

1　引言

1.1　背景与动机

近年来的经验证据表明，大语言模型已经具备可观的数学推理能力。在 Chain-of-Thought（CoT）提示下，模型能够生成人类可读的多步推理链 [13]；在 GSM8K [4] 与 MATH [7] 等基准上，准确率随模型规模与推理时计算量的增加而显著提高。与此同时，将计算外包给程序解释器（Program-of-Thoughts, PoT）[2]、或让模型自行学习调用外部工具（Toolformer）[10]，也都带来了可测量的收益。

然而，这些能力的「可靠性」是脆弱的。自然语言推理链是一个*非类型化*、*概率性*的文本序列：它的每一步都不携带形式语义，因而

*本文为 AI 挑战任务 C2 交付物。写作大纲依据课程一手材料《Lectures on AI for Mathematics》（同济大学，2026）[3]，全部引用文献均经联网核实，见 `references.bib`。

1. **不可直接验证**——只存在「答案对不对」这一末端信号，中间步骤的正确性无法被机械地检查；
2. **不可局部定位**——当结论错误时，无法判定失败发生在哪一步，因为步骤之间没有可推导关系；
3. **不可迁移**——同一条推理链无法被复用到形式系统中，也无法作为证明对象被归档、检索与组合。

与之相对，形式数学系统（Lean 4 [6]、Coq、Isabelle/HOL、SMT 求解器如 Z3 [5]）提供了机器可检查的证明语义：一个被编译器接受的证明对象，其正确性不依赖于生成它的模型是否「说谎」。AlphaGeometry [11]、FunSearch [9] 与 AlphaProof [8] 正是这一路线的代表性成果：AlphaProof 在 2024 年国际数学奥林匹克（IMO）上结合 AlphaGeometry 解出六题中的四题，达到银牌水平，且其推理被形式系统自动验证。

1.2 问题陈述

于是问题自然浮现：*既然两端都足够强，为什么端到端的可靠 AI 数学仍然困难？*

本文的答案是：**缺失的是中间那一段**。生成端（LLM）与验证端（形式系统）之间存在一个语义鸿沟——自然语言命题需要被翻译成形式对象（这一过程称为*自动形式化*，autoformalization [14]）。这一翻译*不是*一个轻量的预处理步骤，而是一个独立的、承载全部正确性风险的系统组件。我们把这一组件称为**语义规约层**。

1.3 核心论点与贡献

本文的核心论点是：

> *可靠 AI 数学推理 ≠ 生成 + 验证。*
> *可靠性不能仅依赖「最终验证」，必须显式引入语义规约层作为中间锚点。*

具体贡献如下：

1. **概念贡献**：提出三层分解模型（§2），把「语义规约」确立为独立且核心的系统层，并论证它是当前系统的主要失败来源（§3）。
2. **方法贡献**：给出以 Typed IR 为核心的框架设计（§4），包括类型系统、操作语义、约束系统与可组合结构，以及「生成 → IR → 验证 → 渲染」的标准流水线。
3. **理论视角**：以 Curry–Howard 对应为语义规约提供类型论基础，并形式化定义*双向一致性约束*（可解释性 + 可回溯性）。
4. **评估贡献**：提出可证伪的实验设计（§7），引入比 accuracy 更敏感的指标——*可验证率*与*回译保真度*。

本文是*立场与方法*论文（position-and-method paper）：我们提出的框架以设计论证与可检验假设的形式给出，实验部分为预注册式的设计说明，而非已完成的实证结果。§8 明确讨论了这一局限。

2 问题分层模型

2.1 三层结构

我们把一个 AI 数学推理系统分解为三个层次，如表 1 所示。

表 1: 三层分解模型：性质、契约与代表工具

层	输出	性质	代表工具/方法
生成层	自然语言推理链	概率性、非类型化、非严格语义	CoT [13]；PoT [2]；Toolformer [10]
语义规约层	结构化形式对象	**承载正确性风险的关键层**	自动形式化 [14]；Typed IR（本文）
验证层	布尔判定 / 证明对象	可靠、可判定（在系统内）、不可欺骗	Lean 4 [6]；Z3 [5]；Coq；Agda

2.2 第一层：生成层（Generation Layer）

生成层接收自然语言问题 $q \in \mathcal{Q}_{\mathrm{NL}}$，产出推理文本 $r = (s_1, s_2, \ldots, s_n)$，其中每个 s_i 是一段自然语言陈述。其性质为：

- **概率性**：$r \sim P_\theta(\cdot \mid q)$，同一输入可产生不同输出；
- **非类型化**：不存在 $\vdash s_i : T$ 这样的类型判定关系；
- **非严格语义**：s_i 的真值不独立于上下文与世界知识。

CoT [13] 展示了该层的核心价值：显式中间步骤可以显著提升多步推理的准确性。但这同时暴露了该层的根本缺陷——步骤的「看起来合理」与「语义正确」之间没有保障。PoT [2] 与 Toolformer [10] 部分缓解了这一点：前者把计算从推理中剥离，交给外部解释器执行；后者让模型学习在何时调用哪个工具。二者的共同思路是「把不可靠的环节外包给可靠系统」——这正是本文所称语义规约的雏形，但它们都只覆盖了计算这一个侧面，未触及语义。

2.3 第二层：语义规约层（Semantic Reduction Layer）

语义规约层的职责是把自然语言陈述映射为形式对象，即定义一个映射

$$\mathrm{Reduce} : \mathcal{Q}_{\mathrm{NL}} \times \mathcal{R}_{\mathrm{NL}} \longrightarrow \mathcal{T}_{\mathrm{IR}}, \tag{1}$$

其中 $\mathcal{R}_{\mathrm{NL}}$ 是推理文本空间，$\mathcal{T}_{\mathrm{IR}}$ 是类型化中间表示的集合。$\mathcal{T}_{\mathrm{IR}}$ 中的元素可以是

- 逻辑表达式（FOL / HOL 公式）；
- 可执行程序（Python / 领域特定语言 DSL）；
- 证明对象（proof objects）；
- 类型化中间表示（Typed IR），即本文主张的统一载体。

该层的理论基础是 **Curry–Howard 对应**（命题即类型、证明即程序）：它保证了「构造一个类型为 T 的项」与「证明命题 T」是同构的。因此，一旦自然语言命题被规约为类型 T，验证问题就化为类型检查问题，而验证层的可靠性可以完全继承。

但严格的对应关系也立刻暴露出该层的困难：自然语言是*欠类型化*的，而类型系统要求*完全类型化*——这个落差必须在该层内部被弥合，且无法由下游的验证层代劳。这正是 §3 要展开的核心。

2.4 第三层：验证层（Verification Layer）

验证层接收形式对象，返回判定结果。其检查内容包括：

- **自洽性**（consistency）：对象内部无矛盾；
- **可推导性**（derivability）：证明对象可由公理与已有定理推出；
- **事实一致性**（factual grounding）：结论与已知数学事实相容；
- **约束满足**（constraint satisfaction）：所有显式约束被满足。

该层的工程可靠性已被充分验证：Lean 4 的 kernel [6] 与 Z3 [5] 都是成熟且久经考验的系统；AlphaProof 的全部成绩都建立在「形式系统自动验证」之上 [8]。因此，*验证层不是瓶颈*——这一判断对后续的归因至关重要。

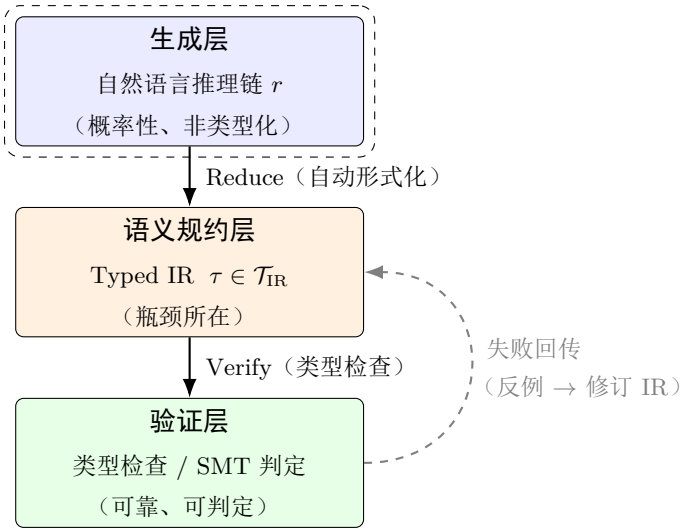


图 1: 三层分解与语义规约层的中心地位。实线为前向流水线，虚线为失败回传路径：验证失败时，修订的对象应是 IR 而非自然语言推理链——这正是把语义规约确立为独立层的直接工程后果。

3 核心问题：语义规约瓶颈

3.1 归因观察

我们对现有系统的失败模式给出如下归因假设：

当前系统的失败主要源于第二层（语义规约），而非生成层或验证层。

这一归因可以被具体的经验事实支持。autoformalization 的原始工作报告：LLM 能够把约 25.3% 的数学竞赛题完美翻译为 Isabelle/HOL 形式规格 [14]——换言之，近四分之三的翻译存在缺陷。与此同时，同一批工作显示，用自动形式化产物训练神经定理证明器后，miniF2F [16] 上的证明率从 29.6% 提升到 35.2%。这说明：涨点来自规约质量，而非生成模型容量。

更近期的证据来自 PutnamBench [12]：这是一个基于 Lean 4 的形式化奥林匹克级基准，其结果显示，即便在强模型上，形式化竞赛数学的通过率仍然很低——失败更多发生在「把题面正确形式化」这一环节，而非「找不到证明」。

3.2 三点结构性困难

我们把该层的困难归纳为三条：

(1) 语义不稳定（ambiguity）. 自然语言命题与形式命题之间不存在确定映射。例如「f 是连续的」在 $\mathbb{R}$ 上至少对应 ε-δ 定义、序列连续、拓扑连续三种形式化，而它们在一般拓扑空间中并不等价。Reduce 因此不是函数，而是一个关系 $\mathrm{Reduce} \subseteq \mathcal{Q}_{\mathrm{NL}} \times \mathcal{T}_{\mathrm{IR}}$。

(2) 类型不完整（missing typing）. 自然语言不携带类型信息。量词的作用域、函数的定义域与值域、集合的宇宙层级，均需由规约层补齐。若补齐错误，得到的形式对象类型正确却语义错误——这类错误最危险，因为它能通过验证层的形式检查，却验证了一个并非原问题的命题。

(3) 映射不可逆（non-invertibility）. Reduce 一般没有逆映射。这意味着无法仅凭 IR 恢复原始意图；若缺少双向约束，系统将丧失可解释性与可回溯性——当验证通过时，人类无法确认「通过的」究竟是原命题还是被悄悄改写过的命题。

3.3 后果

上述三点分别导致：

1. **验证失效**（no handle to verify）：Reduce 不确定时，验证层没有可检查的对象，只能退化为对最终答案的比对；
2. **幻觉不可检测**：一个类型正确但语义漂移的对象会被验证器接受，从而把幻觉「洗白」为已证结论；
3. **错误不可归因**：由于缺少中间锚点，失败无法被定位到具体步骤，迭代改进只能靠盲试。

注记 3.1. 第 *(2)* 点值得强调：验证器的可靠性与系统的可靠性不是同一件事。一个 *100%* 正确的类型检查器，与一个把错误命题形式化的映射组合起来，整体系统的可靠性可以接近零。这是「生成 + 验证」这一朴素配方失效的根本原因。

4 方法框架

4.1 类型化中间表示（Typed IR）

我们主张以统一的 Typed IR 作为语义规约层的输出载体。Typed IR 由四个组件构成：

(a) 类型系统（Type System）. 给定基类型集合 $\mathcal{B}$（如 $\mathbb{N}$、$\mathbb{R}$、Prop）与类型构造子（$\to$、$\times$、Π、Σ），定义类型项

$$T \;::=\; b \mid T \to T \mid T \times T \mid \Pi x{:}T.\,T \mid \Sigma x{:}T.\,T, \qquad b \in \mathcal{B}. \tag{2}$$

(b) 操作语义（Operational Semantics）. 为 IR 的每个构造子给出小步语义规则 $\tau \longrightarrow \tau'$，使 IR 可以被执行（用于程序类对象）或被归约（用于证明类对象）。这使得 IR 不是静态标注，而是可运行的语义载体。

(c) 约束系统（Constraints）. IR 上附加一组约束 $\mathcal{C} = \{c_1, \ldots, c_m\}$，用于编码自然语言中隐含但未言明的前提，例如定义域非空、量词作用域、可测性等。约束可被翻译为 SMT 公式并交由 Z3 [5] 判定。

(d) 可组合结构（Composable Graph / AST）. IR 是一个有向无环图（AST 或 workflow graph），节点是带类型的子对象，边是依赖或蕴含关系。可组合性使得局部修订成为可能：验证失败时，只需回退到失败的子节点重新规约，而不必重写整条推理链。

定义 4.1 (良类型 IR)**.** *称 IR 对象 τ 关于上下文 Γ 是良类型的，记作 $\Gamma \vdash \tau : T$，当且仅当 τ 可由式 (2) 的类型规则推导，且其全部子节点良类型，且 $\mathcal{C}$ 在 τ 上可满足。*

4.2 流水线架构

框架的标准流水线为

$$\underbrace{q}_{\text{自然语言}} \xrightarrow{\text{Reduce}} \underbrace{\tau}_{\text{Typed IR}} \xrightarrow{\text{Verify}} \underbrace{v \in \{\top, \bot\}}_{\text{判定}} \xrightarrow{\text{Render}} \underbrace{\hat{r}}_{\text{自然语言输出}}. \tag{3}$$

关键设计原则是：

自然语言只是 interface；可验证结构才是 execution core。

即：人类读写自然语言，但系统内部的一切计算、传递与判定都发生在 IR 上。Render 负责把验证后的 IR 重新渲染为人类可读的文本/证明说明，但渲染结果不参与正确性判定——它只是 IR 的一个视图。

算法 1 与朴素「CoT 后比对答案」的差别在于：它始终保有一个可检查的形式对象，并把它作为唯一的真相来源（single source of truth）。

4.3 双向一致性

仅有关注前向映射是不够的：Reduce 不可逆，使得前向正确性无法被人类确认。因此我们引入**双向一致性**（Bidirectional Consistency）约束。

定义 4.2 (双向一致性)**.** *设 $\tau = \mathrm{Reduce}(q)$，$\hat{q} = \mathrm{Render}(\tau)$。称 (q, τ) 满足双向一致性，当且仅当*

1. **可解释性**（*interpretability*）：*$\hat{q}$ 是 τ 的一个忠实视图，即 $[\![\hat{q}]\!] = [\![\tau]\!]$；*

Algorithm 1 语义规约驱动的可靠推理（SRR: Semantic-Reduction Reasoning）

Require: 自然语言问题 q；规约器 Reduce；验证器 Verify；渲染器 Render
Ensure: 判定 v 与解释 $\hat{r}$

$\tau_0 \leftarrow \mathrm{Reduce}(q)$ ▷ 初次规约：生成候选 Typed IR
if τ_0 未通过良类型检查（定义 4.1） **then**
  $\tau_0 \leftarrow \textsc{Repair}(\tau_0)$ ▷ 补齐类型/约束，局部修订
end if
$\mathcal{C} \leftarrow \textsc{ExtractConstraints}(\tau_0)$
for all $c \in \mathcal{C}$ **do** ▷ 逐条 SMT 判定，定位失败约束
  if $\mathrm{SMT}(c) = \bot$ **then**
    记录反例 ρ_c；$\tau_0 \leftarrow \textsc{Refine}(\tau_0, \rho_c)$
  end if
end for
$v \leftarrow \mathrm{Verify}(\tau_0)$ ▷ 类型检查 / 形式证明检查
$\hat{r} \leftarrow \mathrm{Render}(\tau_0, v)$ ▷ 渲染为自然语言，附 IR 引用
return $(v, \hat{r}, \tau_0)$ ▷ 一并返回 IR，供审计

2. **可回溯性**（*traceability*）：存在从 $\hat{q}$ 的每个语义单元到 τ 的子结构的一一对应（*alignment*），记作 α。

   可回溯性要求给出对齐映射

$$\alpha : \mathrm{Seg}(\hat{q}) \longrightarrow \mathrm{Sub}(\tau), \tag{4}$$

使得人类可以逐句核对「我看到的这句话」对应 IR 的哪一部分。这直接对抗 §3 中的第 (2)(3) 条困难：类型补齐的每一步都必须显式暴露，语义漂移无法隐藏。

命题 4.1. *若系统满足双向一致性，则任何「类型正确但语义错误」的规约结果（§3 第 (2) 条）在原则上可被人类审计发现。*

证明思路. 由定义 4.2 的可回溯性，存在对齐 α 把 $\hat{q}$ 的每个语义单元映射到 τ 的子结构。若 τ 相对 q 发生了语义漂移，则必存在某个语义单元（如量词作用域、定义域条件）在 $\hat{q}$ 中无对应或对应错位；该错位可由审计者沿 α 比对发现。故漂移不可能在保持 $\hat{q}$ 与原问题逐单元一致的同时不被察觉。 □

注记 4.1. *命题 4.1 是可能性命题而非复杂性命题：它保证漂移可被发现，但不保证审计成本可接受。降低审计成本（例如只审计 α 上置信度最低的若干单元）是一个独立的工程问题。*

5 与现有工作的关系

5.1 推理范式

Chain-of-Thought [13] 奠定了「显式中间步骤」的范式，但它把推理与计算混在同一个文本序列中。PoT [2] 明确把计算剥离给外部解释器，在多个数据集上平均带来约 12% 的增益。

Toolformer [10] 进一步让模型自监督地学会何时调用工具。这三者代表了从「纯文本推理」到「模型 + 外部系统」的演进，但其外部系统承担的是计算，而非语义规约。

5.2 自动形式化与神经定理证明

autoformalization [14] 首次系统性地把「自然语言 → 形式规格」作为独立任务，并报告了 25.3% 的完美翻译率。DeepSeek-Prover [15] 通过大规模合成数据推进了形式定理证明的性能。这些工作是本文框架最直接的先行者：它们事实上构建了语义规约层的雏形。本文的差异在于定位——我们不把自动形式化视为一个待优化的翻译模块，而把它视为决定整个系统可靠性的核心层，并据此提出以 Typed IR 为载体的统一设计，以及双向一致性这样的显式契约。

5.3 神经符号系统

AlphaGeometry [11] 用神经语言模型与符号演绎引擎协同求解奥林匹克几何，无需人类演示；FunSearch [9] 用 LLM 引导的程序搜索在组合数学中发现了新的构造；AlphaProof [8] 通过强化学习在 Lean 环境中学习证明，在 2024 IMO 上达到银牌水平；PatternBoost [1] 在局部搜索与全局 transformer 之间交替，为若干长期开放问题找到了更好的构造，包括一个悬置 30 年的猜想的反例。这些系统是强证据：形式化环境 + 可靠验证器 + 搜索/学习，确实可以产生可验证的新数学。它们的共同特征是把正确性锚定在形式系统上——这与本文的主张一致。本文补充的是：当输入来自自然语言（而非预先形式化的题面）时，锚定本身需要一整个语义规约层来支撑。

表 2: 与现有工作的定位对比

工作	计算外包	语义规约	形式验证	规约层地位
CoT [13]	否	否	否	无
PoT [2]	是	否	否	无（仅计算）
Toolformer [10]	是（多工具）	否	否	无
autoformalization [14]	否	**是**	是	作为翻译模块
AlphaProof [8]	是	隐含	**是**	隐含在 RL 流程中
本文	是（IR 可执行）	**是（核心）**	是	**独立核心层 + 双向契约**

5.4 本文的差异

如表 2 所示，本文与已有工作的差别不在「是否使用形式验证」（多数工作都用了），而在是否把语义规约确立为独立的、有显式契约的系统层。我们把这一层的形式化缺口总结为三点：缺少统一载体（Typed IR）、缺少双向契约（可解释性 + 可回溯性）、缺少专门的评估指标。

6 应用场景

6.1 自动定理证明（ATP）

在证明辅助环境（Lean 4 [6]、Coq）中，工作流为：LLM 生成证明草图 → 规约为 IR → 展开为形式证明项 → 内核检查。与 AlphaProof 式流程的差别在于：我们把「草图 → IR」这一步显式化，并允许在人机协作中让人类审计 IR（利用定义 4.2 的对齐映射）。这对教学与审稿场景尤其有价值——人类需要理解证明为什么对，而不只是知道它被接受了。

6.2 数学解题系统

对文字应用题（word problems，如 GSM8K [4]），标准流程为：题面 → 类型化程序 → 执行器求解。这与 PoT [2] 的下游结构相同；本文的补充是在「题面 → 程序」之间插入显式类型标注与约束提取（$\mathcal{C}$），使「单位、定义域、边界条件」这类隐含前提不再被静默丢弃。

6.3 教学与评估

在教育场景中，学生解答本身是自然语言。框架可把学生解答规约为 IR，然后在 IR 层做结构化诊断：不只判定对错，而是定位到「哪一步的类型/约束出了问题」。这比基于最终答案的评分更有信息量，且由于 IR 可回溯，反馈可以对齐到学生的原句（式 (4)）。

7 实验设计

7.1 数据集

选择三个层次分明的数据集，以分离「计算难度」与「规约难度」：

- **GSM8K** [4]：小学应用题，计算简单，规约中等；
- **MATH** [7]：竞赛级数学，计算与规约均变难；
- **miniF2F** [16] 与 **PutnamBench** [12]：直接以形式系统为后端，规约难度最高。

7.2 对比设置

表 3: 实验对比设置

组	系统	说明
A	纯 LLM（CoT）	仅生成层，答案比对式评估
B	LLM + 外部计算（PoT 式）	生成层 + 计算外包
C	LLM + 形式验证（端到端自动形式化）	生成层 + 规约 + 验证，但规约层不显式化
D	**本文框架（SRR, 算法 1）**	**显式 Typed IR + 双向一致性契约**

7.3 评估指标

除常规正确率外，我们提出三个针对规约层的指标：

(1) 正确率（accuracy）. $\mathrm{Acc} = \frac{1}{N}\sum_i \mathbb{1}[\hat{a}_i = a_i]$，其中 $\hat{a}_i$ 为系统答案，a_i 为参考答案。这是可比基线。

(2) 可验证率（verifiability）. 定义

$$\mathrm{Ver} = \frac{\#\{\, i : \Gamma \vdash \tau_i : T_i \text{ 且 } \mathcal{C}_i \text{ 可满足} \,\}}{N}. \tag{5}$$

它度量「有多少比例的输入被成功规约为良类型 IR」。这是该框架下最灵敏的指标——若 Ver 低，则系统退化为 A 组，无论生成层多强。

(3) 回译保真度（back-translation fidelity）. 定义

$$\mathrm{Fid} = \frac{1}{N}\sum_i \mathrm{Sim}\big(q_i,\ \mathrm{Render}(\tau_i)\big), \tag{6}$$

其中 Sim 采用人工评分（盲评）或参考答案约束下的语义等价判定。Fid 直接检验双向一致性（定义 4.2）是否成立。

7.4 假设

- **H1（归因假设）**：在 MATH 与 miniF2F 上，C 组相对 B 组的失败增量主要来自 Reduce（可用 Ver 的下降解释），而非 Verify。
- **H2（框架假设）**：D 组在 Ver 与 Fid 上显著优于 C 组，且这一优势在规约难度最高的 PutnamBench 上最大。
- **H3（边界假设）**：在 GSM8K 上，D 组相对 A/B 的优势有限——因为简单题目的规约难度低，语义规约层的边际收益小。

注记 7.1. *H3 是刻意设置的证伪性预测：若框架在所有数据集上都有大幅优势，反而提示指标设计存在漏洞（例如泄漏了额外信息）。一个诚实的方法论文应当给出自己不适用的边界。*

8 讨论

8.1 局限

(1) 本框架尚未完成端到端实证. 本文给出的是设计论证与可检验假设，实验部分（§7）是预注册式方案而非已完成结果。因此，H1–H3 目前处于待检验状态。这是本文最主要的局限。

(2) IR 设计复杂、成本高. 设计一个既表达力充分又可判定的类型系统，需要领域特定的权衡；每个新领域（分析、代数、组合）都需要扩展 IR 的构造子。这与 FunSearch [9] 式的「轻量 LLM + 现成搜索」相比，前期投入显著更高。

(3) 语义映射成本高. Reduce 的调用可能涉及多次 LLM 请求 + 形式检查，成本随问题复杂度上升。在低价值场景（如简单算术）中入不敷出——这正是 H3 所指的边界。

(4) 双向一致性的审计成本. 命题 4.1 只保证漂移「可被发现」，不保证廉价。对齐映射 α 的人工核查仍需成本。

8.2 扩展方向

(1) 通用推理系统. 把 Typed IR 从数学推广到一般演绎推理（法律、程序验证、科学论证），其中「命题」与「证据」同样存在自然语言与形式对象之间的鸿沟。

(2) Agent 系统. 在多智能体架构中，每个 agent 的中间结论都应是可审计的 IR 对象，而非自由文本。这等价于把本文的双向一致性契约作为 agent 间通信协议，从而使多 agent 协作*可验证*而非仅仅是「看起来协调」。这与课程材料中提到的 agent 架构方向一致 [3]。

(3) 与搜索/学习结合. IR 的图结构天然适合作为搜索空间：可把 PatternBoost [1] 式的局部/全局交替搜索应用到 IR 图上，用「验证是否通过」作为唯一的奖励信号——因为该信号完全可靠（由验证层保证），这使得强化学习的目标函数免于被幻觉污染。

9 结论

本文的核心结论可凝练为一个等式：

$$\boxed{\text{可靠 AI 推理} \;=\; \text{生成} \;+\; \text{语义规约} \;+\; \text{验证}} \tag{7}$$

其中三项缺一不可，且*语义规约*是当前最薄弱、也最常被隐式跳过的一环。

本文的关键贡献有两项：

1. 明确提出「**语义规约层**」是可靠 AI 数学的核心瓶颈，以三层分解模型给出可检验的归因假设（H1）；
2. 提供以 **Typed IR** 为载体的结构化路径，配合双向一致性契约与三个新指标，把「可靠性」从口号变为可测量的工程目标。

从更广的视角看，本文主张的转变是：*不要把自然语言当作系统的内部表示*。自然语言适合作为人机接口，但可靠性必须在结构化的、可验证的表示上获得。这一原则不限于数学——任何「生成 $\to$ 需要被相信」的场景，都需要同样的中间层。

致谢

本文写作大纲参考了课程一手材料《Lectures on AI for Mathematics》[3]。全部引用均经联网逐条核实；核实方法与记录见随附的 `AI 日志.md`（阶段 2）。

参考文献

[1] François Charton, Jordan S. Ellenberg, Adam Zsolt Wagner, and Geordie Williamson. PatternBoost: Constructions in mathematics with a little help from AI. *arXiv preprint arXiv:2411.00566*, 2024. URL `https://arxiv.org/abs/2411.00566`.

[2] Wenhu Chen, Xueguang Ma, Xinyi Wang, and William W. Cohen. Program of thoughts prompting: Disentangling computation from reasoning for numerical reasoning tasks. *Transactions on Machine Learning Research (TMLR)*, 2023. URL `https://arxiv.org/abs/2211.12588`. arXiv:2211.12588.

[3] Xiaoyang Chen and Xiang Jiang. Lectures on AI for mathematics (version 1.0). Lecture Notes, Tongji University, April 2026. 112 pages, dated 2026-04-11.

[4] Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John Schulman. Training verifiers to solve math word problems. In *arXiv preprint arXiv:2110.14168*, 2021. URL `https://arxiv.org/abs/2110.14168`.

[5] Leonardo de Moura and Nikolaj Bjørner. Z3: An efficient SMT solver. In *Tools and Algorithms for the Construction and Analysis of Systems (TACAS 2008)*, volume 4963 of *Lecture Notes in Computer Science*, pages 337–340. Springer, 2008. doi: 10.1007/978-3-540-78800-3_24.

[6] Leonardo de Moura and Sebastian Ullrich. The Lean 4 theorem prover and programming language. In *Automated Deduction – CADE 28*, volume 12699 of *Lecture Notes in Computer Science*, pages 625–635. Springer, 2021. doi: 10.1007/978-3-030-79876-5_37.

[7] Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. Measuring mathematical problem solving with the MATH dataset. In *Advances in Neural Information Processing Systems 34 (NeurIPS 2021), Datasets and Benchmarks Track*, 2021. URL `https://arxiv.org/abs/2103.03874`. arXiv:2103.03874.

[8] Thomas Hubert, Rishi Mehta, Laurent Sartran, Miklós Z. Horváth, et al. Olympiad-level formal mathematical reasoning with reinforcement learning. *Nature*, 651:607–613, 2025. doi: 10.1038/s41586-025-09833-y.

[9] Bernardino Romera-Paredes, Mohammadamin Barekatain, Alexander Novikov, Matej Balog, M. Pawan Kumar, Emilien Dupont, Francisco J. R. Ruiz, Jordan S. Ellenberg, Pengming Wang, Omar Fawzi, Pushmeet Kohli, and Alhussein Fawzi. Mathematical discoveries from program search with large language models. *Nature*, 625(7995):468–475, 2024. doi: 10.1038/s41586-023-06924-6.

[10] Timo Schick, Jane Dwivedi-Yu, Roberto Dessì, Roberta Raileanu, Maria Lomeli, Luke Zettlemoyer, Nicola Cancedda, and Thomas Scialom. Toolformer: Language models can teach themselves to use tools. In *Advances in Neural Information Processing Systems 36 (NeurIPS 2023)*, 2023. URL https://arxiv.org/abs/2302.04761. arXiv:2302.04761.

[11] Trieu H. Trinh, Yuhuai Wu, Quoc V. Le, He He, and Thang Luong. Solving olympiad geometry without human demonstrations. *Nature*, 625(7995):476–482, 2024. doi: 10.1038/s41586-023-06747-5.

[12] George Tsoukalas, Jasper Lee, John Jennings, Jimmy Xin, Michelle Ding, Michael Jennings, Amitayush Thakur, and Swarat Chaudhuri. PutnamBench: A benchmark for evaluating neural theorem provers on formal mathematical olympiad problems. In *Advances in Neural Information Processing Systems 37 (NeurIPS 2024), Datasets and Benchmarks Track*, 2024. URL https://arxiv.org/abs/2407.11214. arXiv:2407.11214.

[13] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed H. Chi, Quoc V. Le, and Denny Zhou. Chain-of-thought prompting elicits reasoning in large language models. In *Advances in Neural Information Processing Systems 35 (NeurIPS 2022)*, 2022. URL https://arxiv.org/abs/2201.11903. arXiv:2201.11903.

[14] Yuhuai Wu, Albert Q. Jiang, Wenda Li, Markus N. Rabe, Charles Staats, Mateja Jamnik, and Christian Szegedy. Autoformalization with large language models. In *Advances in Neural Information Processing Systems 35 (NeurIPS 2022)*, pages 32353–32368, 2022. URL https://arxiv.org/abs/2205.12615. arXiv:2205.12615.

[15] Huajian Xin, Daya Guo, Zhihong Shao, Z. Z. Ren, Qihao Zhu, Bo Liu, Chong Ruan, Wenda Li, and Xiaodan Liang. DeepSeek-Prover: Advancing theorem proving in LLMs through large-scale synthetic data. *arXiv preprint arXiv:2405.14333*, 2024. URL https://arxiv.org/abs/2405.14333.

[16] Kunhao Zheng, Jesse Michael Han, and Stanislas Polu. miniF2F: A cross-system benchmark for formal olympiad-level mathematics. In *International Conference on Learning Representations (ICLR 2022)*, 2022. URL https://arxiv.org/abs/2109.00110. arXiv:2109.00110.